Análise Bibliométrica em Profundidade e Estruturação TEMAC

Este documento apresenta uma análise exaustiva dos resultados exportados via Bibliometrix (Scopus), com o objetivo de fornecer um alicerce robusto para a condução de uma Revisão Sistemática da Literatura (RSL). O relatório está dividido em duas partes: (I) Análise detalhada dos dados e (II) Síntese baseada na Metodologia TEMAC.

PARTE I: ANÁLISE DETALHADA DOS RESULTADOS BIBLIOMÉTRICOS

1. Informações Principais e Crescimento da Produção Científica

- **Visão Geral (MainInfo.csv):** A amostra é composta por 3.192 documentos publicados entre 2016 e 2026. Um dado crucial é a tipologia documental: **1.548 são *Conference Papers*** e **1.033 são *Articles***. Em áreas de rápida inovação tecnológica (como Ciência da Computação e Engenharia de Dados), as conferências são o principal veículo de disseminação, validando tecnologias antes que cheguem aos periódicos tradicionais.
- **Crescimento Exponencial:** A produção saltou de 149 publicações (2016) para 948 (2025), como pode-se observar na Figura 1.

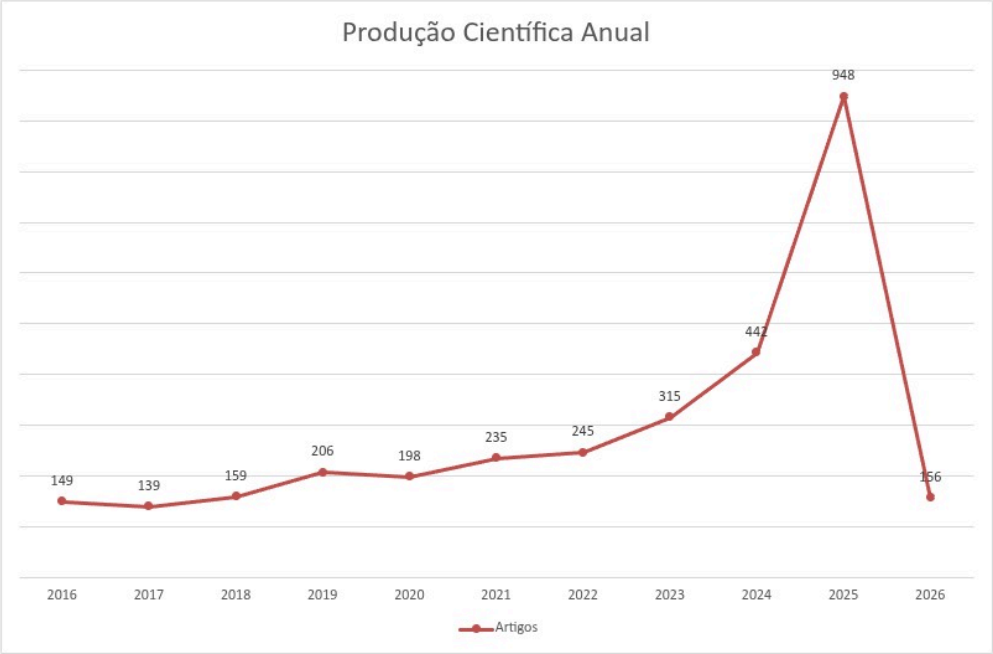

Figura 1. Produção científica anual

- **Impacto das Citações:** Os anos de 2018 e 2021 apresentam as maiores médias de citações por ano. Artigos publicados neste período formam a base consolidada do conhecimento atual.

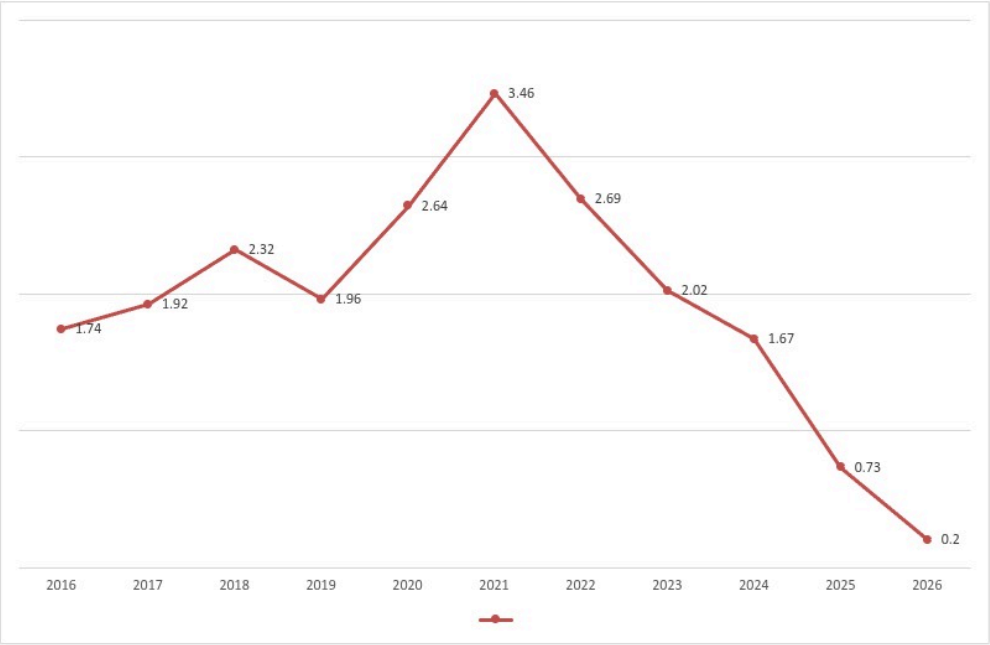

Figura 2. Quantidade média de citações por ano

2. Análise de Fontes (Periódicos e Eventos)

- **Lei de Bradford:** A lei de dispersão de Bradford indica que o "Núcleo 1" (Zone 1) do tema é

composto por cerca de 79 fontes, ou seja, o primeiro terço da quantidade total de pesquisas é representado pelas 79 fontes. Essa será a zona principal de pesquisas.

- **Fontes Mais Relevantes e com Maior Impacto:** As séries *Lecture Notes in Computer Science* (105 artigos, h-index 14) e *Lecture Notes in Networks and Systems* (73 artigos) lideram em volume. No entanto, o **IEEE Access** (41 artigos, 767 citações, h-index 13) e o **Procedia Computer Science** (33 artigos, 818 citações) são as fontes de **maior impacto**. Notavelmente, periódicos como *Sensors* e *Sustainability* aparecem no topo, mostrando, provavelmente, que o tema está sendo aplicado em IoT e Sustentabilidade.

3. Análise de Autores e Padrões de Colaboração

- **Produtividade vs. Impacto:** Autores asiáticos dominam a produção (ZHANG Y, LI X, WANG Y), conforme figura 3. Contudo, o impacto local revela uma anomalia fundamental: **BALAC N possui 1.160 citações locais**, um valor absurdamente superior ao segundo colocado (QUIX C, com 62), conforme figura 4. Balac N é o "autor âncora" desta rede de conhecimento, ou seja, é o autor com trabalhos considerados mais importantes. Cabe destacar ainda os seguintes resultados:
  - **Liderança por TC (Citações)**: O autor LI Y possui o maior impacto local (TC = 605), o que significa que ele é a maior referência teórica dentro desse grupo de documentos, seguido por WANG H (TC = 400).
  - **Eficiência (Impacto vs. Quantidade)**: Note que LIU Z tem um impacto local alto (TC = 392) com apenas 16 publicações (NP), enquanto ZHANG Y tem 44 publicações mas um impacto bem menor (TC = 190). Isso mostra que os trabalhos de LIU Z são mais influentes para esse tema específico.
  - **Consolidação (m-index)**: Autores como GRÖGER C e LIU Z têm o maior m-index (0.875), indicando que atingiram um impacto relevante em menos tempo (carreira mais "produtiva" recentemente dentro do tema).

COLOCAR AQUI MAIS INFORMACOES DO ZHANG Y.

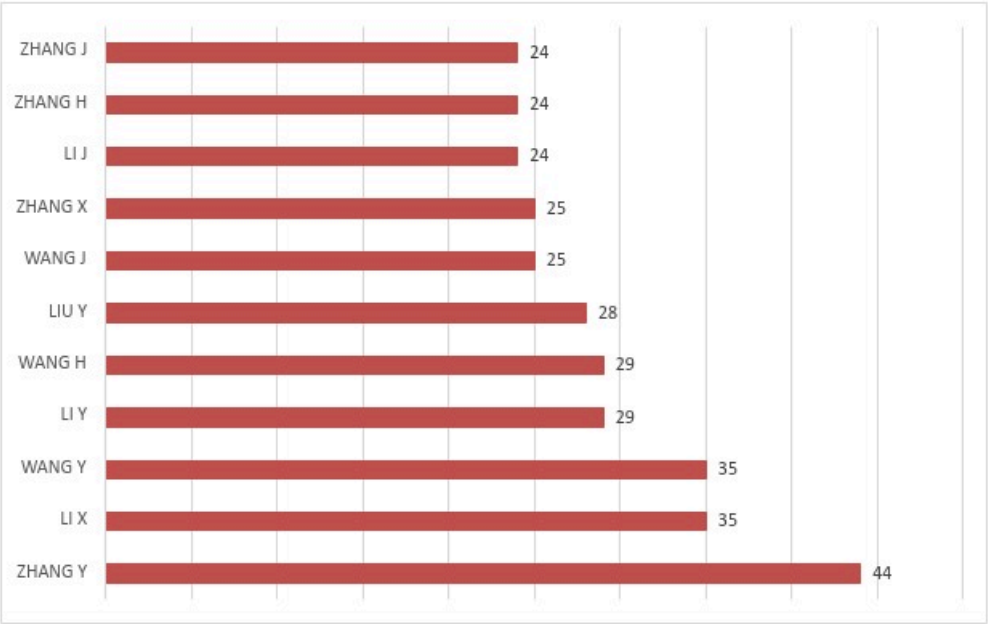

Figura 3. Quantidade total de artigos produzidos por autor (2016-2026)

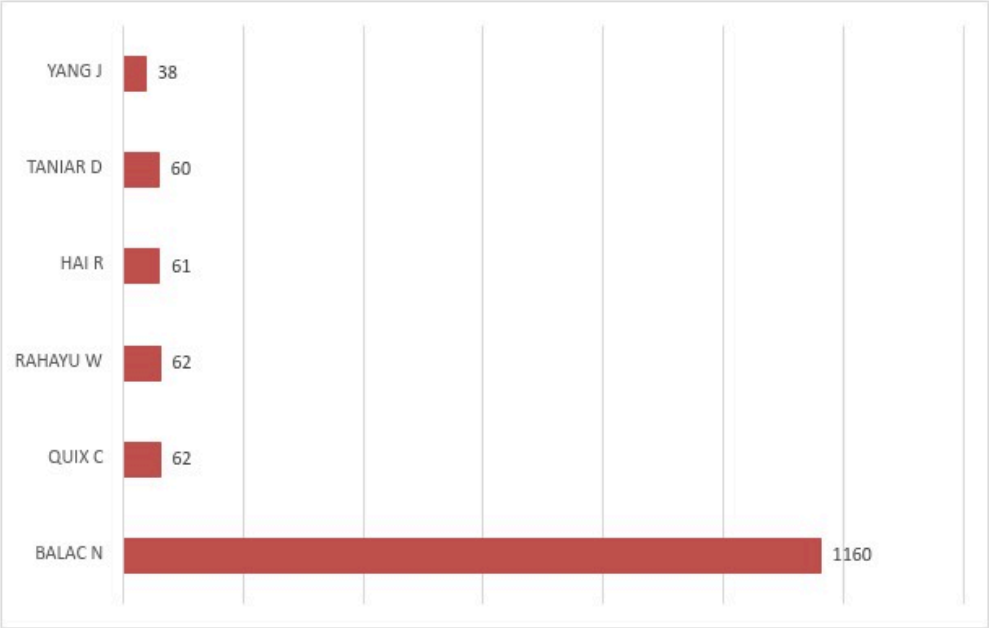

Figura 4. Quantidade total de citações por autor (2016-2026)

COLOCAR AQUI MAIS INFORMACOES DO BALAC N.

- **Lei de Lotka:** 85,5% dos autores (8.570) escreveram apenas 1 artigo. Isso pode caracterizar um campo de pesquisa "fragmentado" e altamente interdisciplinar. Provavelmente muitos pesquisadores "visitam" o tema para resolver um problema específico de suas áreas e não retornam.
- **Redes de Colaboração:** A rede de colaboração mostra fortes laços entre autores de origem chinesa (Zhang, Li, Wang), formando o maior *cluster* (colégio invisível) da amostra, conforme figura 5.

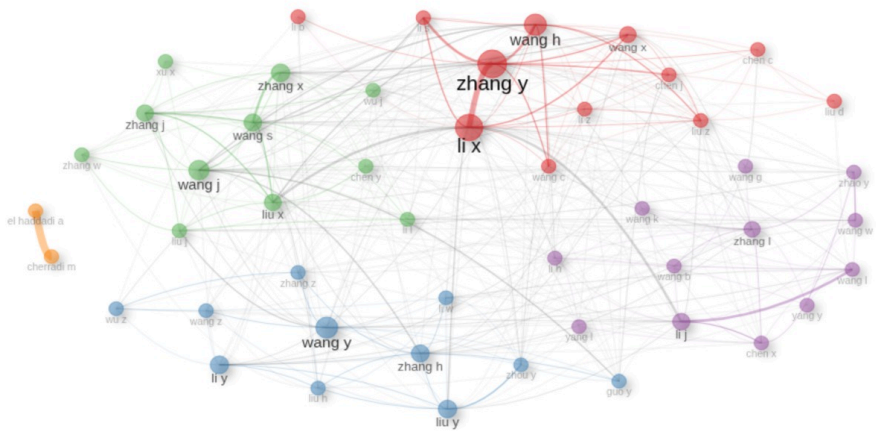

Figura 5. Rede de colaboração entre autores (2016-2026)

4. Distribuição Geográfica e Institucional

- **Dominância Asiática:** A **China** é o motor do tema (1.549 publicações), seguida pela Índia (1.132) e EUA (755). Na Europa, Itália (348) e Alemanha (315) lideram.
- **Instituições e Casos de Uso:** Excluindo o erro de reporte (31 trabalhos sem o metadado de afiliação), as três instituições mais produtivas são chinesas: Jiangsu University (23), Beihang University (20) e Tongji University (19). Isso indica que o centro de gravidade da produção acadêmica deste tema específico está fortemente concentrado na China. Além disso, tem-se:
    - **Área Médica/Saúde**: A presença da Fondazione Policlinico Gemelli (18) sugere que existem aplicações do tema na área da saúde ou biotecnologia.
    - **Engenharia e Tecnologia**: Universidades como Tsinghua (18) e Politecnico di Milano (16) reforçam um viés tecnológico ou de engenharia.
    - **Presença Lusófona**: A Universidade do Minho (17) aparece com destaque.
    - **Termo Genérico**: O item "College of Engineering" (17) é um erro comum de padronização. Provavelmente refere-se a faculdades de engenharia de diferentes universidades que o software não conseguiu agrupar corretamente sob o nome da instituição principal.
- **Colaboração Global:** A maior ponte de colaboração ocorre entre China e EUA, e China e Austrália. Há um "deserto" de colaborações no hemisfério sul (África e América do Sul).
- **Produção por país:** A figura 6 mostra um aumento, ao longo dos anos, da produção científica na área de pesquisa, destacando-se a China, em primeiro lugar e a Índia em segundo. Porém pode-se perceber que, apesar de produzir mais artigos que o Estados

Unidos, este último possui mais impacto em termos de citação que a Índia.

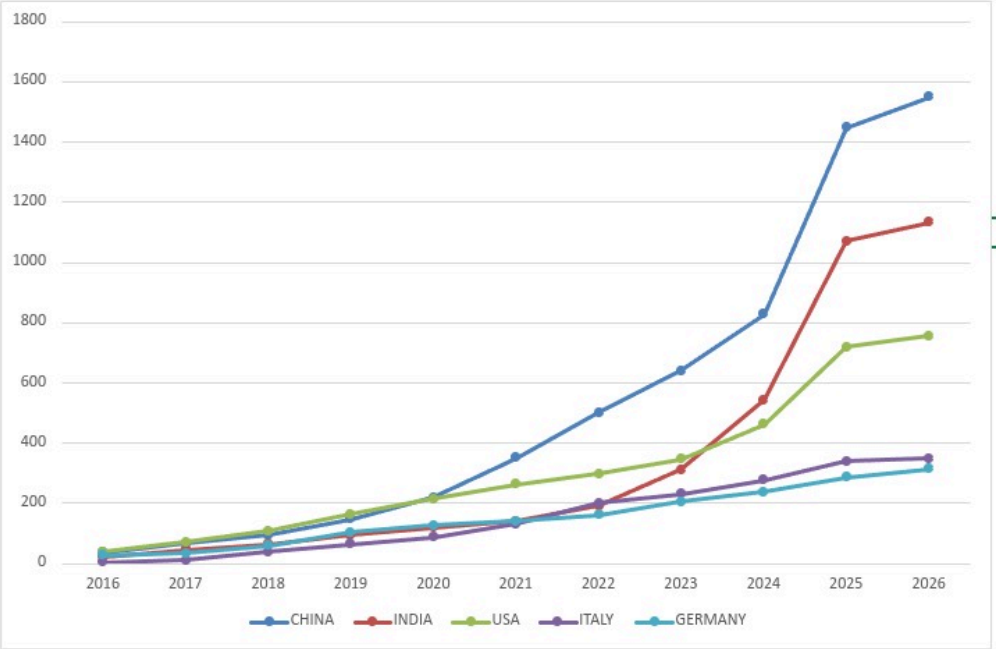

Figura 6. Produção de pesquisas por páis (os mais relevantes) ao longo dos anos.

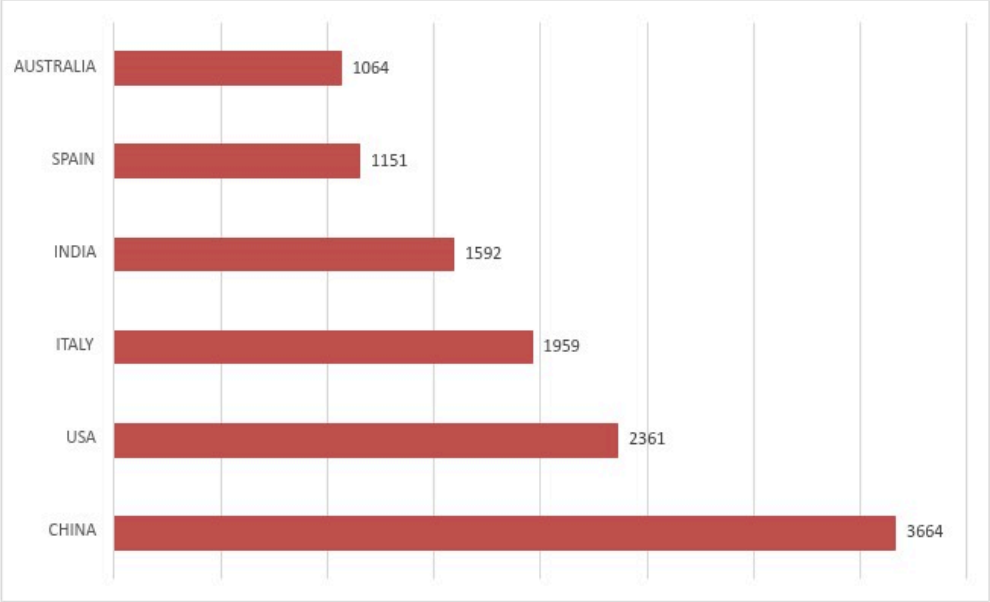

Figura 7. Países mais citados ao longo dos anos.

5. Documentos Seminais e Espectroscopia (RPYS)

- **Documentos Globais vs. Locais:** O artigo mais citado globalmente é ***Francia M, 2021* (839 citações, focado em Future Generation Computer Systems)**, que representa o número total de citações que um artigo recebeu em toda a base de dados. Mas o documento mais importante, que representa o número de citações que um documento recebeu de outros

artigos que fazem parte da amostra de interesse da pesquisa, é o mais citado localmente: **Balac N, 2020 (Intell Internet of Things: From Device To Fog and Cloud)**, conforme figuras 8 e 9.

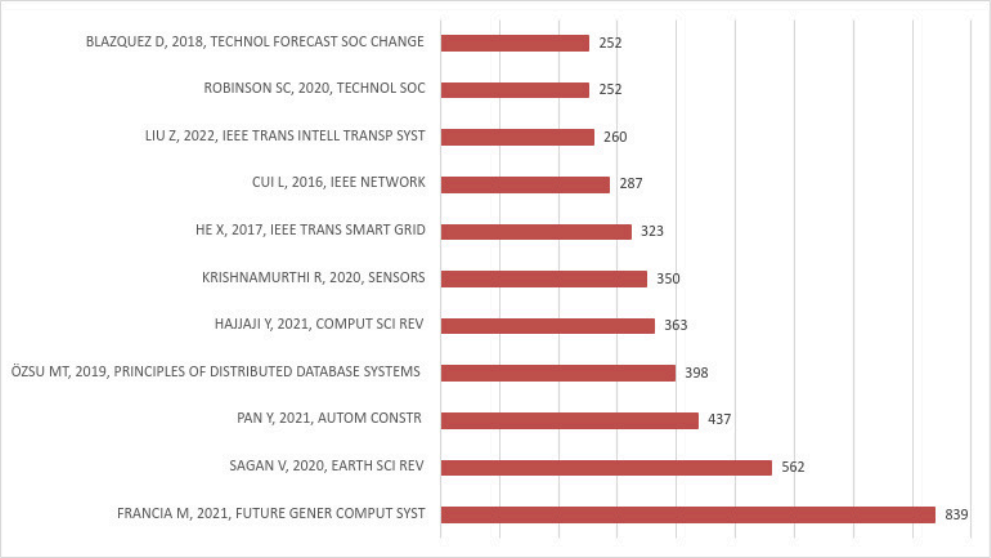

Figura 8. Documentos globais mais citados.

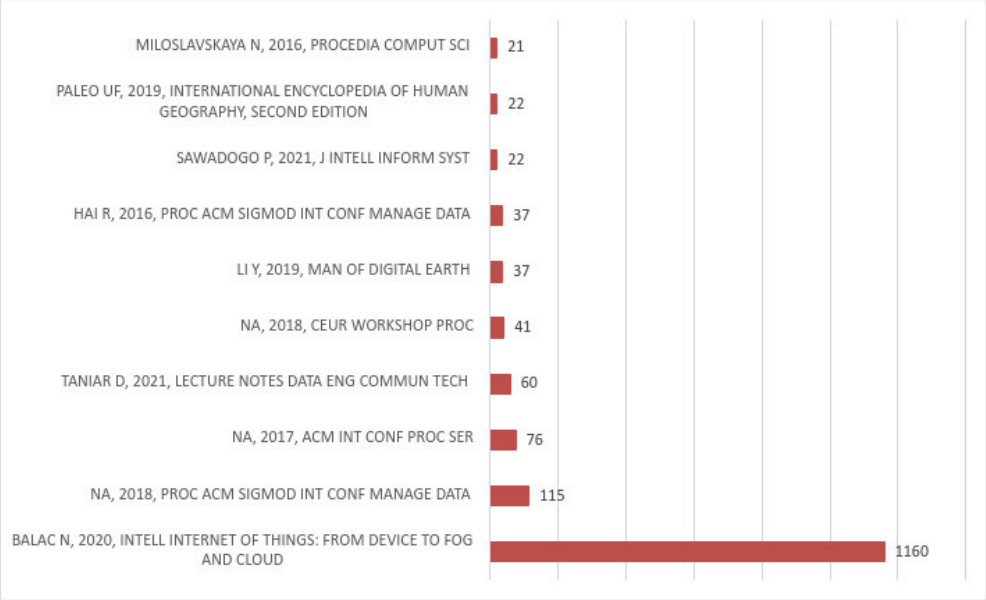

Figura 9. Documentos locais mais citados.

- **A Raiz Teórica:** O RPYS (Espectroscopia de Ano de Publicação) mostra "picos" históricos que fundaram a área:
  - **2004/2008:** O nascimento do processamento distribuído (Trabalho de Dean J. sobre *MapReduce*).
  - **2011/2014:** A explosão do *Big Data* (Trabalho de Chen, 2014).
  - **2015/2016:** A conceitualização do *Data Lake* (Trabalho seminal de Fang, 2015).
  - **2021:** A evolução para o *Lakehouse* (Trabalho de Armbrust, 2021).

6. Temática, Palavras-chave e Tendências

- **Frequência Absoluta:** A palavra mais frequente não é uma tecnologia, mas um objetivo de negócio: **Decision Making (1.065)**, superando Big Data (1.044) e Data Integration (897), conforme figura 9.

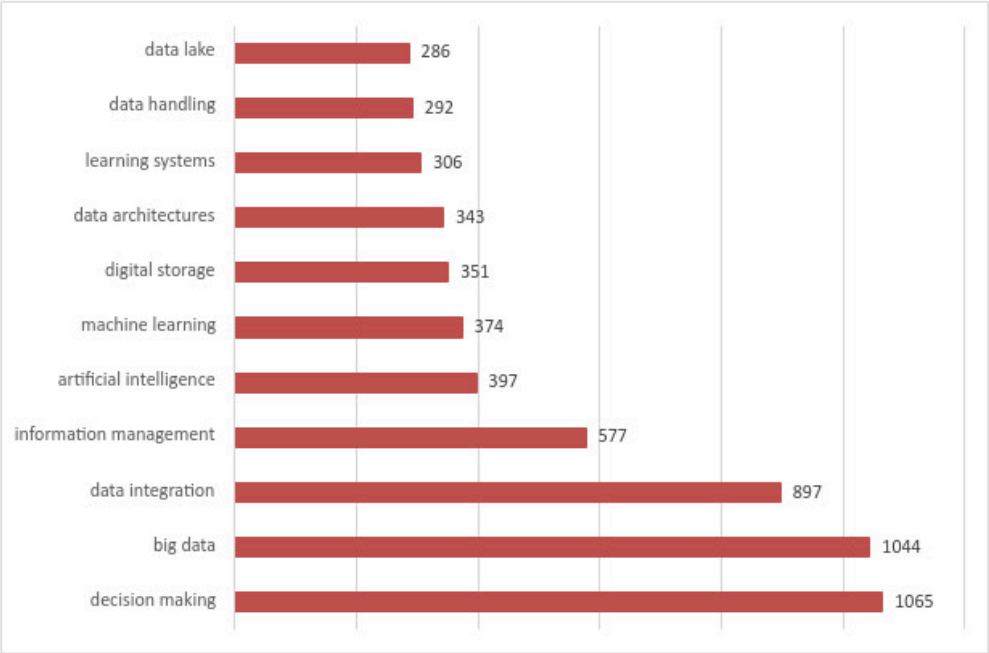

Figura 10. Palavras mais frequentes.

- **Evolução Temática:** Pode-se, a partir da figura 11, propor três recortes de tempo com os termos mais frequentes:

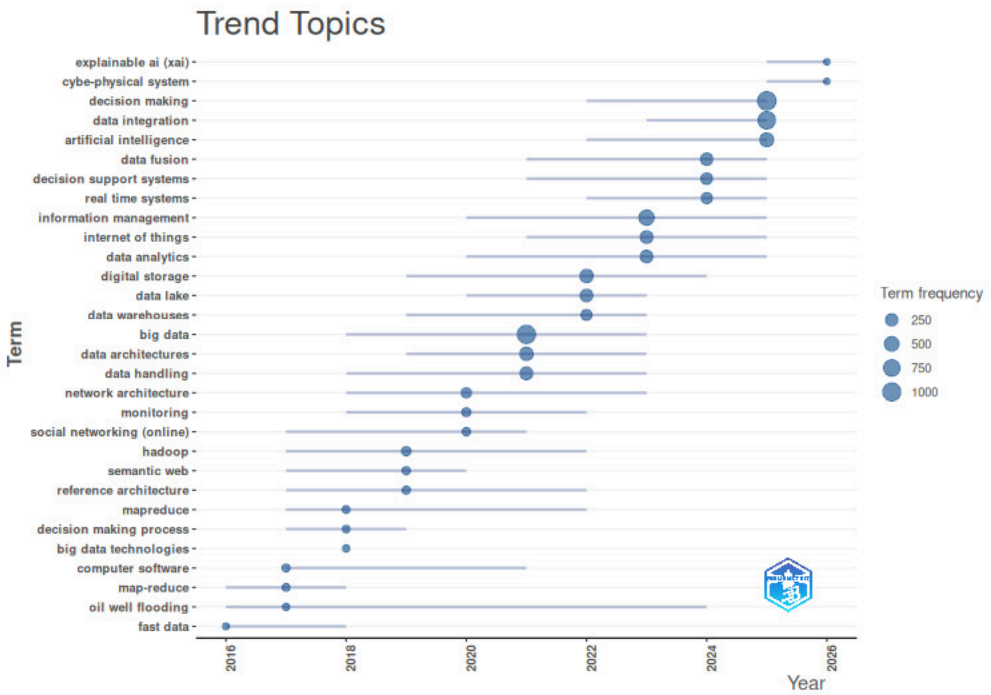

Figura 11. Distribuição das palavras mais relevantes no tempo.

- *Passado (2016-2019):* Hadoop, MapReduce, Fast Data. (Tecnologia de infraestrutura).
- *Presente (2020-2022):* Data Architectures, Digital Storage, Data Handling. (Gestão e arquitetura).
- *Futuro (2022-Atualidade):* Network Architecture, Digital Twin, Predictive Analytics. (Uso da inteligência em tempo real).
- **Mapa Temático:** O *Decision Making* (Tomada de Decisão) juntamente com *IoT* e *Data Integration* formam os temas motores (alta centralidade e alta densidade), ou seja, são o coração do desenvolvimento atual.

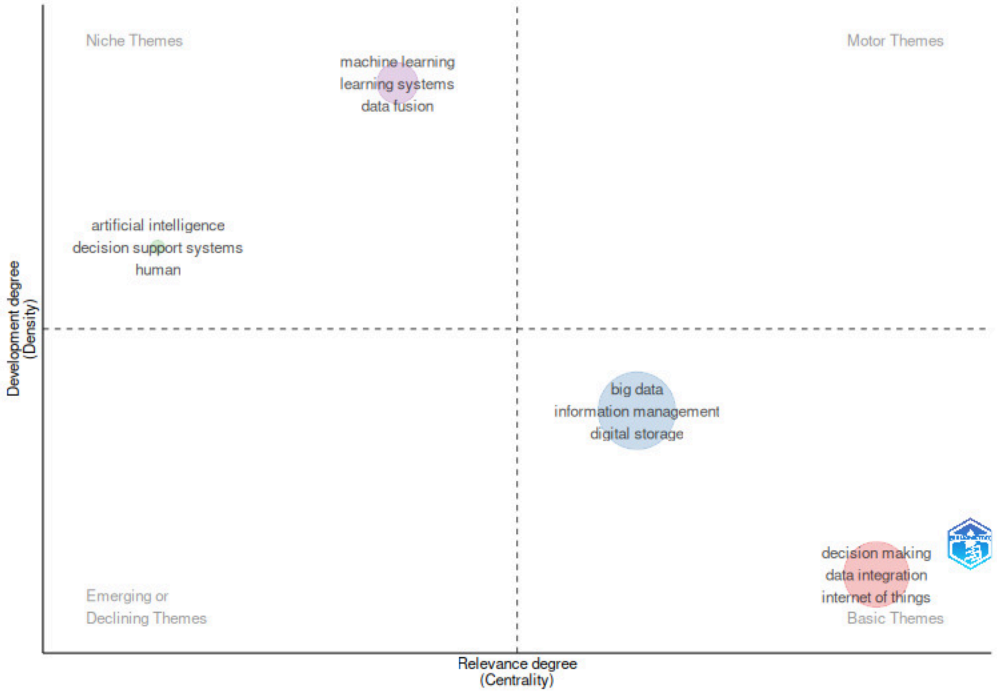

Figura 12. Mapa temático dos tópicos.

PARTE II: SÍNTESE METODOLÓGICA T-E-M-A-C

Com base na interpretação aprofundada acima, estruturamos os pilares para a escrita da sua Revisão Sistemática da Literatura.

T - Teoria (A base conceptual)

A literatura sofreu uma mutação teórica evidente. A teoria de base evoluiu do mero "processamento distribuído em lote" (*batch processing* suportado pela teoria do MapReduce de 2008) para o conceito de **Arquiteturas de Gestão Dinâmica**.

- **Fundamento Central:** A transição do conceito de *Data Warehouse* (dados estruturados) para *Data Lakes* (dados brutos e heterogêneos), formalizada por autores como Fang (2015) e Hai (2016).
- **Evolução Teórica Atual:** O estado da arte teórico atual, ancorado nos trabalhos de Balac (2020) e Armbrust (2021), postula a necessidade de arquiteturas híbridas (*Lakehouses*) integradas à computação em nuvem e névoa (*Fog computing*) para lidar com a Internet das Coisas.

E - Empiria (O campo de observação e prática)

A empiria desta área do conhecimento é caracterizada por testes massivos em escala, liderados pelo eixo Asiático (China e Índia).

- **Domínios de Aplicação:** Os dados bibliométricos confirmam que a experimentação saiu dos laboratórios de computação. A presença forte de publicações na área médica (Hospital Policlinico Gemelli), em revistas de *Sustainability* e *Automation in Construction*, mostra que as arquiteturas de dados estão sendo testadas empiricamente na **Saúde Inteligente (Smart Health)**, **Cidades Inteligentes (Smart Cities)** e **Construção Civil/Engenharia (Digital Twins)**.
- **Lacunas Empíricas (Research Gaps):** Existe uma vasta lacuna empírica na aplicação dessas tecnologias em cenários de infraestrutura precária ou ambientes de baixo orçamento, típicos do Sul Global (América Latina e África), visto que a produção nestas regiões é estatisticamente irrelevante na amostra global.

M - Metodologia (Ferramentas e técnicas de resolução)

Para resolver os desafios da arquitetura de dados modernos, a literatura abandonou métodos puramente estatísticos e abraçou a computação avançada.

- **Inteligência Habilitadora:** O uso de **Artificial Intelligence** (397) e **Machine Learning** (374) são as metodologias padrão (*gold standard*) atuais para promover a *Data Fusion* (fusão de dados) e o refinamento do *Data Lake*.
- **Maturidade Metodológica:** A análise fatorial aponta para uma clusterização metodológica focada em **Deep Learning** e **Predictive Analytics**. A metodologia vigente não procura apenas "entender o que aconteceu" com os dados, mas usar algoritmos de aprendizagem profunda para "prever o que vai acontecer" com altíssima velocidade (*real-time systems*).

A - Análise (O foco do escrutínio dos pesquisadores)

O que os investigadores estão realmente a analisar quando recolhem e processam todo este volume de dados?

- **Tomada de Decisão:** O objetivo principal de todas as arquiteturas propostas na literatura não é o armazenamento em si, mas o **Decision Making**. A análise científica recai sobre como criar *Decision Support Systems* que sejam rápidos e confiáveis.

- **Representação Virtual:** Uma forte tendência analítica recente é o **Digital Twin** (Gêmeo Digital). A análise da literatura foca em como utilizar a integração de dados para criar simulações perfeitas de sistemas físicos no mundo digital, permitindo testes analíticos sem risco de operação (usado na indústria 4.0 e hospitais).

C - Contexto (O ambiente circundante)

O contexto tecnológico, social e de mercado que exige essas pesquisas.

- **Gatilho Contextual (IoT):** A *Internet of Things* (IoT) é o grande motor. O contexto atual é um mundo hiper-sensorizado. Sensores industriais, smartwatches, veículos autônomos geram um tsunami de dados desestruturados em tempo real, tornando as antigas arquiteturas (Hadoop) obsoletas devido à latência.
- **Contexto de Maturidade:** Como indicado pelo ciclo de vida da produção (*LifeCycle.csv*), o campo entrou na sua fase de estabilização pós-pico (2024-2025). O contexto atual não é mais "inventar a tecnologia de Data Lake", mas focar na **governança de dados, privacidade (Data Privacy) e qualidade da informação (Metadata Management)**.

💡 Recomendações Estratégicas Finais para a RSL

1. **Foco Temporal:** Defina a janela da sua revisão sistemática para artigos publicados **após 2018/2019**. Textos anteriores discutirão infraestruturas (como Hadoop puro) que já não refletem a fronteira de inovação analítica exigida pelos novos *frameworks* de IA.
2. **Busca em Conferências:** Não restrinja sua busca bibliográfica apenas a periódicos revisados por pares (*journals*). O cerne inovador da área (1.548 documentos) reside nos *Conference Papers* (*Lecture Notes in Computer Science*, etc.). Excluí-los causará um grave viés na sua RSL.
3. **Sugestão de Pergunta de Pesquisa (RQ):** Baseado na metodologia TEMAC extraída, uma excelente pergunta para sua revisão seria: *"Como a integração de Machine Learning em Data Lakes (M) otimiza os Sistemas de Apoio à Tomada de Decisão (A) em contextos aplicados de Saúde/Indústria (E/C)?"*